Ciencia de Datos

Semana 1

Tema 1. Conociendo las bases de datos y su arquitectura

¿Qué es una base de datos?

Una base de datos es una colección organizada, estructurada y relacionada de datos que se almacena de forma sistemática para facilitar su gestión, consulta y actualización eficiente.

Características detalladas

- **Organización sistemática:** Los datos siguen un esquema predefinido y lógico
- **Persistencia:** La información se mantiene disponible incluso cuando el sistema se apaga
- **Consistencia:** Los datos mantienen su coherencia y validez en todo momento
- **Concurrencia:** Múltiples usuarios pueden acceder simultáneamente
- **Seguridad:** Control de acceso y protección contra pérdida de datos
- **Integridad referencial:** Las relaciones entre datos se mantienen correctas
- **Escalabilidad:** Puede crecer y adaptarse a mayores volúmenes de información

¿Por qué surgieron las bd?

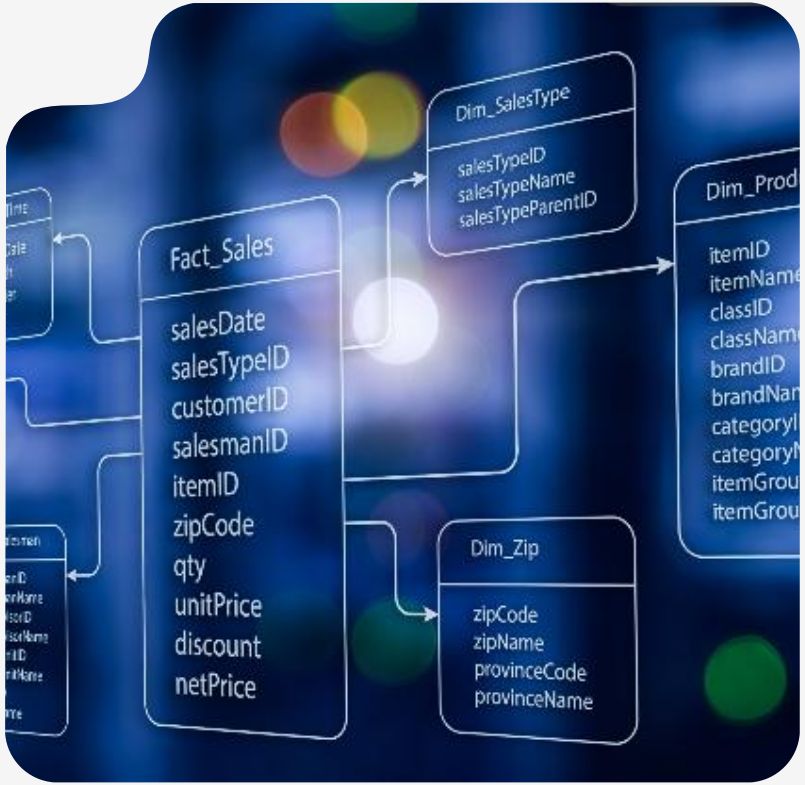

Por que había problemas al manejar la información:

- **Duplicación de información:**
  El mismo dato podía estar en varios archivos, desperdiciando espacio y dificultando la actualización.
- **Inconsistencias en los datos:**
  Al duplicar la información, era común que un dato se actualizara en un archivo pero no en otro, generando información contradictoria.
- **Dificultad para compartir información:**
  Los archivos independientes no estaban diseñados para ser accedidos por múltiples usuarios o aplicaciones al mismo tiempo, lo que limitaba su uso.
- **Problemas de seguridad y respaldo:**
  Era complicado controlar quién tenía acceso a qué información y asegurar que todos los archivos estuvieran respaldados de forma correcta y consistente.

Tipos de bases de datos

Las **bases de datos relacionales (SQL)** son la piedra angular de la gestión de datos estructurados.

Características:

- Organizadas en tablas con filas y columnas
- Usan claves primarias y foráneas para relacionar datos
- Lenguaje SQL para consultas
- Garantizan propiedades ACID (Atomicidad, Consistencia, Aislamiento, Durabilidad)

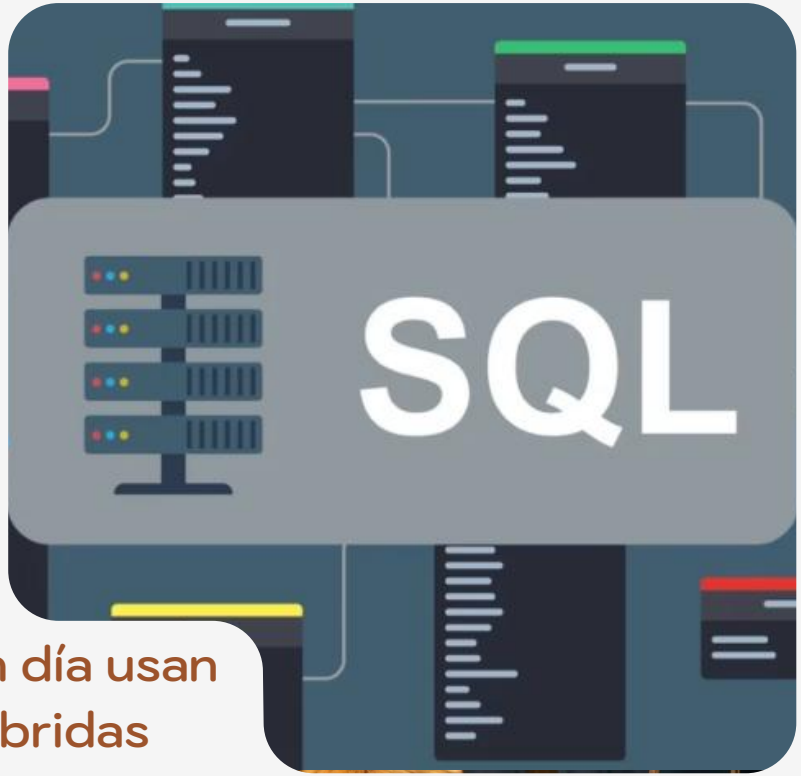

Las empresas hoy en día usan bases de datos híbridas

¿Hay otros tipos de bases de datos?

Por ejemplo, la imagen presenta una Arquitectura **Polyglot Persistence**.
Esta arquitectura utiliza múltiples tipos de bases de datos especializadas según las necesidades específicas de cada funcionalidad.

Tipos de bases de datos que usa

- **Documental**: Contenido flexible (posts, comentarios)
- **Grafos**: Algoritmos de recomendación social
- **Clave-valor**: Cache y sesiones de alta velocidad
- **Búsqueda**: Queries complejas de texto
- **Series temporales**: Analytics y métricas en tiempo real
- **Relacional**: Transacciones ACID críticas (facturación, usuarios)

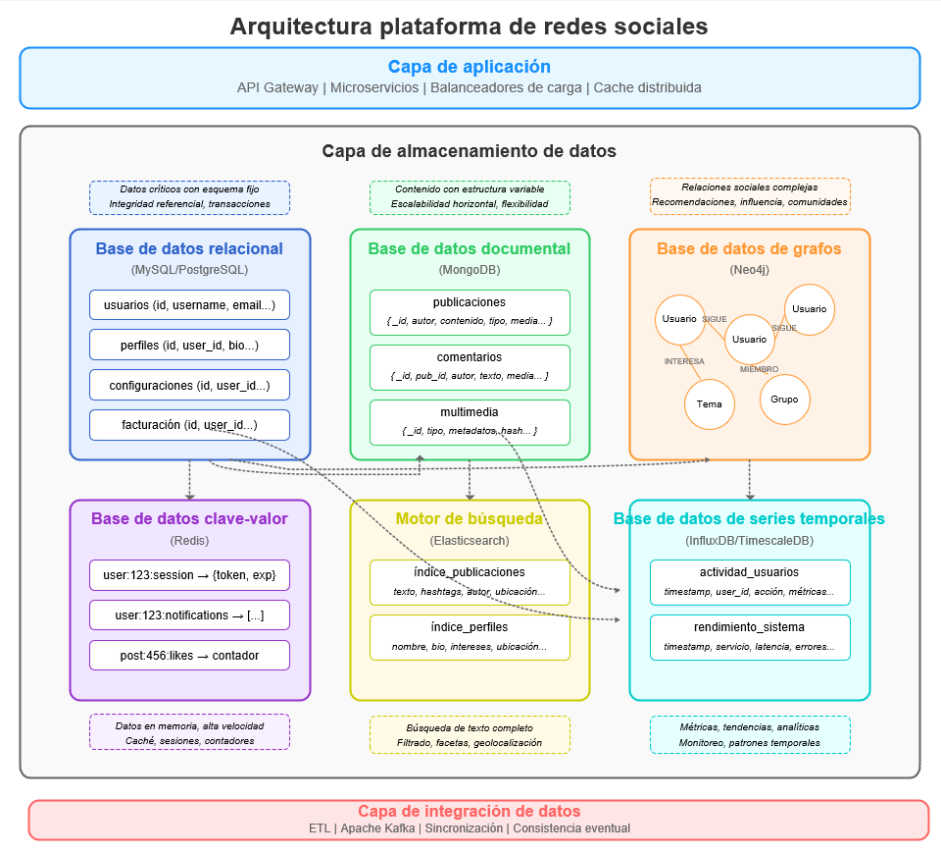

Organización bases de datos relacionales

Las **bases de datos relacionales** se organizan en **tablas** (también llamadas relaciones), que son como hojas de cálculo, estas tablas tienen:

- **Filas (registros o tuplas):** Representan una instancia de la entidad. Por ejemplo, en una tabla de **Clientes**, cada **fila** contendría los datos de un solo **cliente**.
- **Columnas (atributos):** Representan las propiedades de la entidad. En la misma tabla de **Clientes**, las columnas podrían ser **cliente_id**, nombre, apellido, email y teléfono.

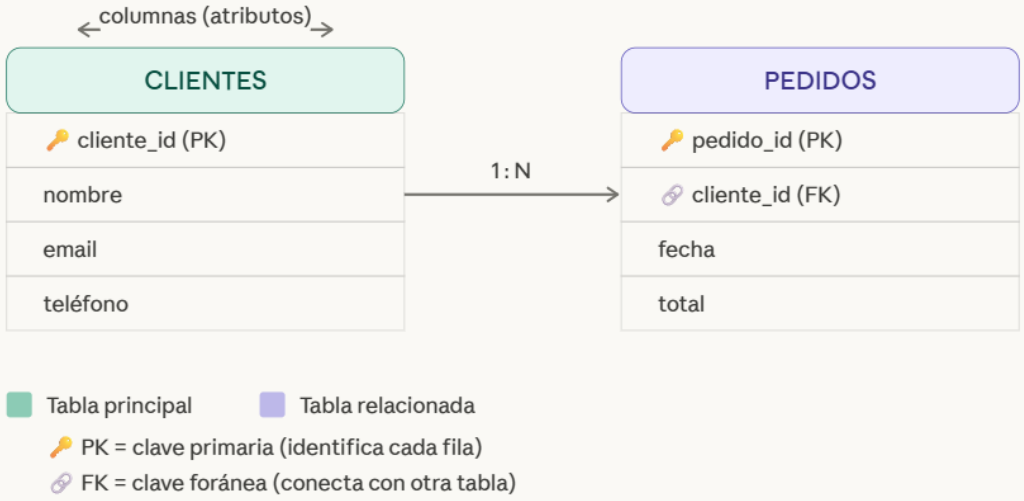

Esta estructura simple y bien definida facilita la comprensión de los datos y permite un acceso eficiente.

Uso de claves primarias y foráneas para relacionar datos

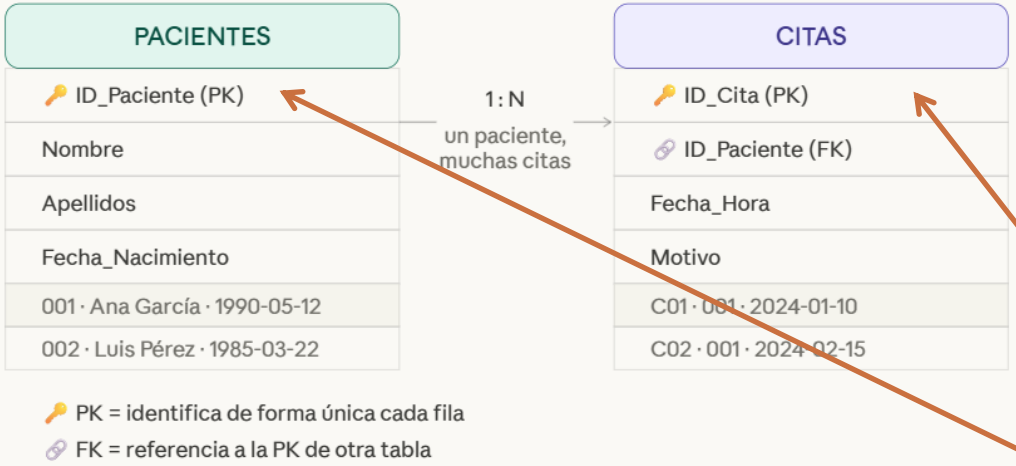

Clave primaria (Primary Key, PK):

Una clave primaria es un campo que **identifica de forma única cada fila en una tabla**.
Es fundamental para asegurar que no haya duplicación de registros.

En la tabla **CITAS**, la clave primaria **(PK)** es **ID_Cita**. Cada cita programada tiene un identificador único.

En la tabla **PACIENTES**, el campo **ID_Paciente** es la clave primaria **(PK).**
Esto garantiza que cada paciente en el sistema tenga una identificación única y que no se puedan confundir sus datos con los de otro.

Aquí es donde el término "**relacional**" cobra sentido. En lugar de tener una sola tabla gigante con datos repetidos, la **información se divide en múltiples tablas** y se **vincula lógicamente (con relaciones)**.

Uso de claves primarias y foráneas para relacionar datos

Clave foránea (Foreign Key, FK):

Una clave foránea es un **campo en una tabla que se relaciona con la clave primaria de otra tabla.** Esto es lo que crea los vínculos entre los datos, permitiendo que la base de datos funcione como un todo.

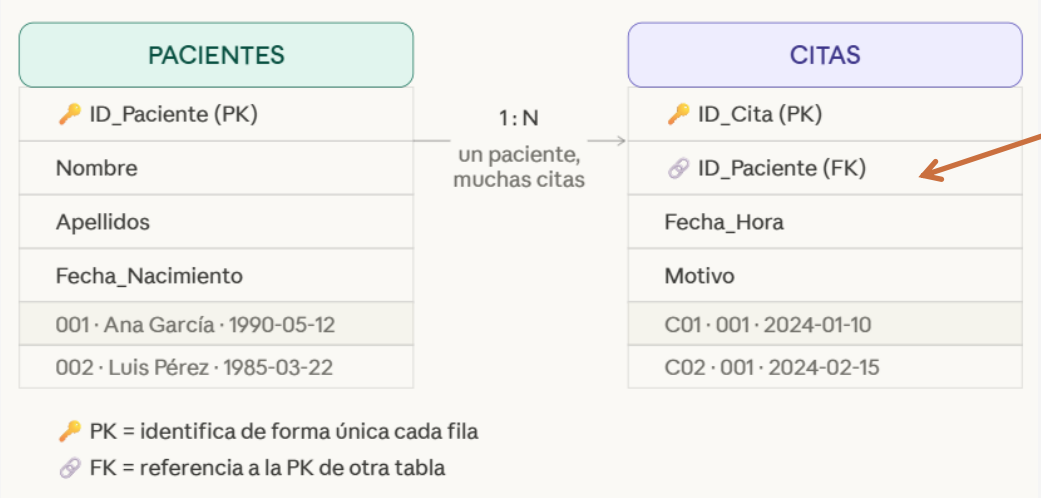

En la tabla **Citas**, el campo **ID_Paciente** es una **clave foránea (FK).**

Se relaciona con la clave primaria **ID_Paciente** de la tabla **Pacientes**. Esta conexión permite que la base de datos sepa exactamente a qué paciente pertenece cada cita.

¿Qué es el diagrama entidad-relación (ER)?

El **diagrama entidad-relación (DER o ER)** es una herramienta visual que nos permite **representar** la **estructura** de una **base de datos** antes de construirla. Nos ayuda a identificar qué información necesitamos guardar y cómo se conecta entre sí.

Un DER tiene **entidades**, **atributos** y **relaciones**.

① **Entidades**

Ej. PACIENTES, CITAS, MÉDICOS → rectángulos

PACIENTES | CITAS | MÉDICOS

② **Atributos**

Ej. ID_Paciente, Nombre, Fecha_Hora → propiedades de cada entidad. La PK identifica cada fila de forma única.

PACIENTES	CITAS	MÉDICOS
🔑 ID_Paciente (PK)	🔑 ID_Cita (PK)	🔑 ID_Medico (PK)
Nombre	🔗 ID_Paciente (FK)	Nombre
Apellidos	🔗 ID_Medico (FK)	Especialidad
Fecha_Nacimiento	Fecha_Hora	Teléfono

③ **Relaciones**

Un paciente *agenda* muchas citas. Un médico *atiende* muchas citas.

¿Qué es el la cardinalidad?

La cardinalidad indica **cuántas instancias de una entidad se pueden relacionar con cuántas instancias de otra.**
En otras palabras, define **cómo se conectan las tablas entre sí**, y de eso depende **cómo se estructuran las claves foráneas.**
Dicho de forma más simple: es la regla que dice **"¿cuántos de A pueden relacionarse con cuántos de B?"**

En el ejemplo del hospital, la pregunta sería por ejemplo:
¿puede un médico atender a más de un paciente?
¿puede un paciente tener más de una cita? Esas respuestas son exactamente la cardinalidad.

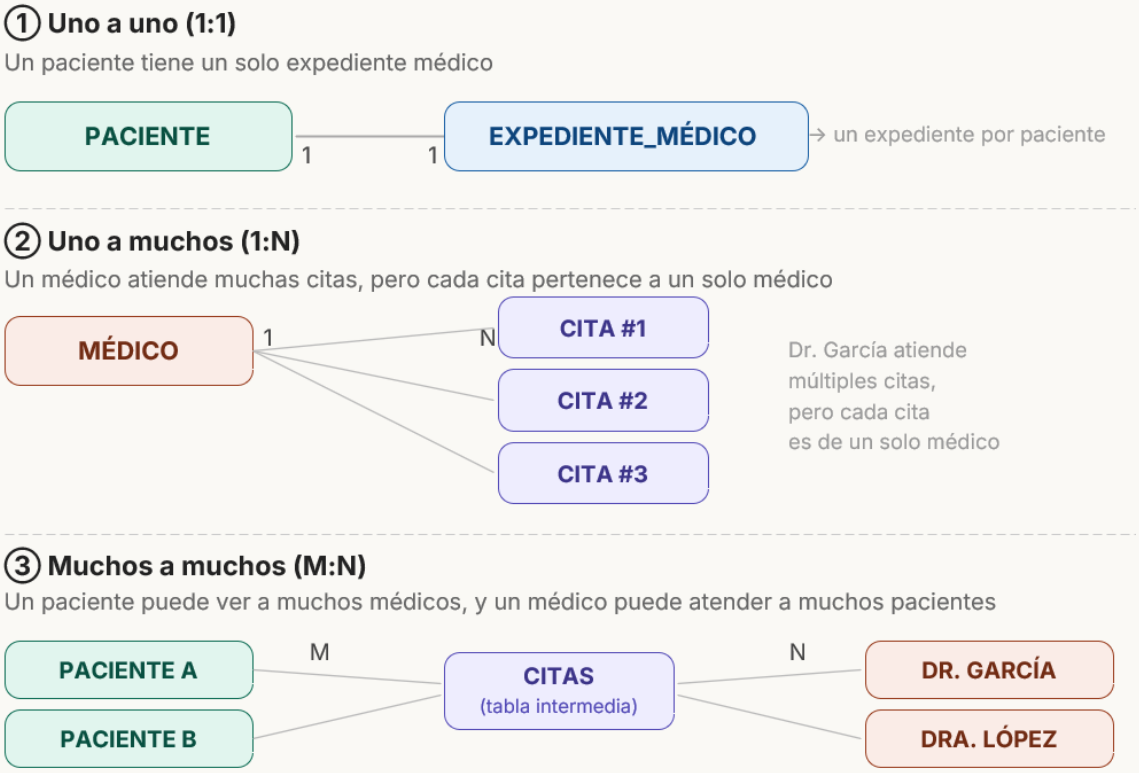

¿Qué es la normalización?

La normalización es el proceso de organizar bien una base de datos desde el diseño. La idea central es simple: **cada dato se guarda en un solo lugar**.
Cuando un dato está duplicado en varias tablas, tarde o temprano algo sale mal, lo actualizas en un lado y se te olvida en otro, y de repente tu base de datos tiene información contradictoria. La normalización evita exactamente eso.

En concreto, normalizar sirve para:

- ❑ **Eliminar redundancia:** no repetir el mismo dato en múltiples lugares
- ❑ **Evitar anomalías:** que al insertar, modificar o borrar un registro no se rompa nada
- ❑ **Garantizar consistencia:** que la información sea confiable en todo momento
- ❑ **Optimizar almacenamiento:** no guardar lo mismo dos veces

Normalización: 1fn y 2fn

01

¿Qué es la normalización 1fn?

Es la Primera Forma Normal (1FN)

La Primera Forma Normal establece que **cada celda de una tabla debe contener un solo valor atómico** (indivisible) y **no debe haber grupos repetitivos**. Esto significa:

1. **Valores atómicos**: Cada campo debe contener un único valor, no listas o conjuntos de valores
2. **No grupos repetitivos**: No debe haber columnas que representen el mismo tipo de dato repetido
3. **Clave primaria**: Cada fila debe ser única y identificable

Ejemplo

Imagina que tienes la siguiente tabla de una base de datos de **estudiantes**:

Id	Nombre	Teléfonos	Cursos
1	Ana López	555-0101, 555-0102	Matemáticas, Física, Química
2	Juan Pérez	555-0201	Historia, Literatura
3	María García	555-0301, 555-0302, 555-0303	Biología

¿Qué es la normalización 1fn?

Ejemplo con la Primera Forma Normal (1FN)

Id	Nombre	Teléfonos	Cursos
1	Ana López	555-0101, 555-0102	Matemáticas, Física, Química
2	Juan Pérez	555-0201	Historia, Literatura
3	María García	555-0301, 555-0302, 555-0303	Biología

Problemas identificados

- La columna "**Teléfonos**" contiene múltiples valores separados por comas
- La columna "**Cursos**" contiene múltiples valores
- Es difícil buscar, actualizar o consultar datos específicos

¿Qué es la normalización 1fn?

Ejemplo con la Primera Forma Normal (1FN)

Id	Nombre	Teléfonos	Cursos
1	Ana López	555-0101, 555-0102	Matemáticas, Física, Química
2	Juan Pérez	555-0201	Historia, Literatura
3	María García	555-0301, 555-0302, 555-0303	Biología

Solución

Tabla estudiantes:

Información básica de cada estudiante

- ID (clave primaria)
- Nombre

Tabla telefonos:

Un registro por cada teléfono

- estudiante_id (clave foránea)
- telefono

Tabla estudiante_cursos:

Relación entre estudiantes y cursos

- estudiante_id (clave foránea)
- Curso

¿Qué es la normalización 1fn?

Ejemplo con la Primera Forma Normal (1FN)

Id	Nombre	Teléfonos	Cursos
1	Ana López	555-0101, 555-0102	Matemáticas, Física, Química
2	Juan Pérez	555-0201	Historia, Literatura
3	María García	555-0301, 555-0302, 555-0303	Biología

Solución gráfica

estudiantes

ID	Nombre
1	Ana López
2	Juan Pérez
3	María García

telefonos

estudiante_id	telefono
1	555-0101
1	555-0102
2	555-0201
3	555-0301

estudiante_cursos

estudiante_id	curso
1	Matemáticas
1	Física
1	Química
2	Historia
2	Literatura

¿Qué es la normalización 1fn?

Ejemplo con la Primera Forma Normal (1FN) y su diagrama entidad relación

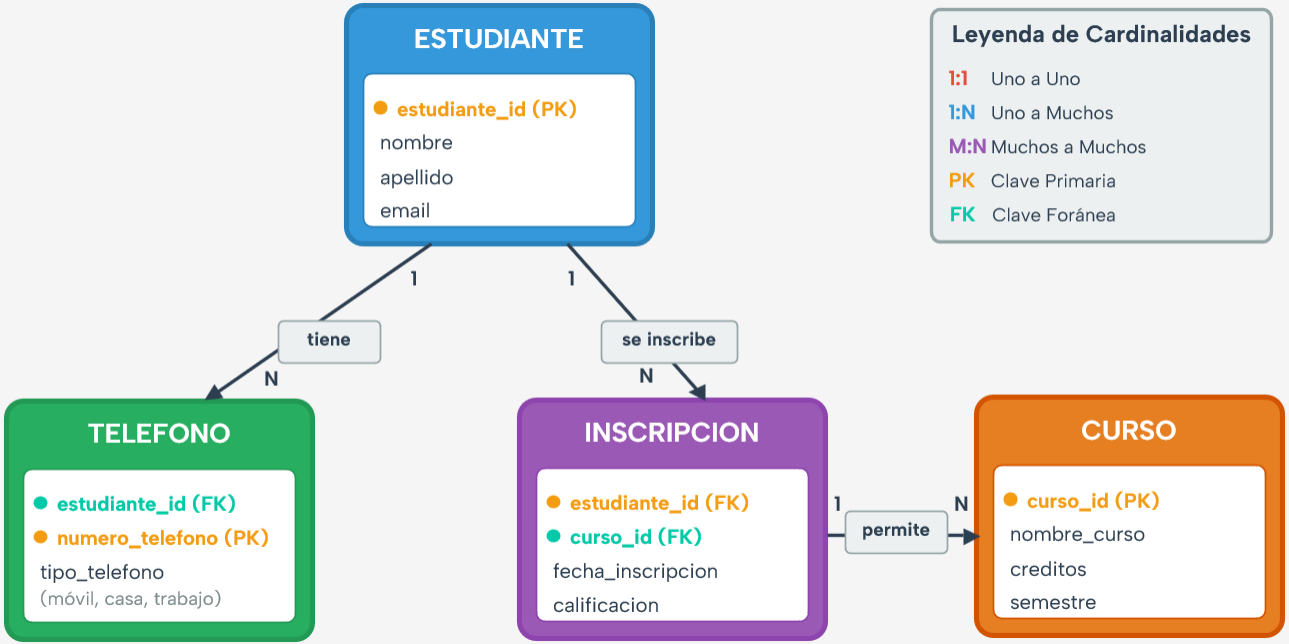

Leyenda de Cardinalidades

- **1:1** Uno a Uno
- **1:N** Uno a Muchos
- **M:N** Muchos a Muchos
- **PK** Clave Primaria
- **FK** Clave Foránea

Explicación de las cardinalidades

1. Estudiante → Teléfono (1:N)

- Un estudiante puede tener MUCHOS teléfonos
- Un teléfono pertenece a UN SOLO estudiante

2. Estudiante ↔ Curso (M:N)

- Un estudiante puede inscribirse en MUCHOS cursos
- Un curso puede tener MUCHOS estudiantes

Se resuelve con tabla INSCRIPCION

Cumplimiento de 1FN:

- ✅ Valores atómicos únicamente
- ✅ No grupos repetitivos
- ✅ Claves primarias definidas
- ✅ Relaciones bien estructuradas

¿Qué es la normalización 2fn?

¿Qué es la Segunda Forma Normal (2FN)?

Tienes una tabla de ventas donde cada fila **combina una venta con un producto**.
Para identificar cada fila necesitas dos datos juntos: el venta_id y el producto_id.

A eso le llamamos **clave primaria compuesta**.
El problema aparece cuando te das cuenta de que **algunos datos de esa tabla no necesitan los dos campos para existir**:

- **¿Para qué necesitas saber el venta_id si quieres saber el nombre_producto?** Con solo el producto_id ya sabes que P001 es "Laptop Dell" a $15,000 — no importa en qué venta aparezca.
- **¿Para qué necesitas el producto_id si quieres saber quién es el cliente?** Con solo el venta_id ya sabes que la venta 1001 es de Juan Pérez con teléfono 555-0123 — sin importar qué productos compró.

Ejemplo
Tabla **ventas**:

venta_id	producto_id	nombre_producto	cantidad	precio_unidad	subtotal	nombre_cliente	telefono_cliente
1001	P001	Laptop Dell	2	15000	30000	Juan Pérez	555-0123
1001	P002	Mouse Logitech	3	250	750	Juan Pérez	555-0123
1001	P003	Teclado HP	1	800	800	Juan Pérez	555-0123
1002	P001	Laptop Dell	1	15000	15000	Ana García	555-0456
1002	P004	Monitor Samsung	2	3500	7000	Ana García	555-0456
1003	P002	Mouse Logitech	5	250	1250	Carlos López	555-0789
1003	P003	Teclado HP	2	800	1600	Carlos López	555-0789
1004	P005	Impresora Canon	1	4500	4500	María Torres	555-0321

¿Qué es la normalización 2fn?

Solución a la Segunda Forma Normal (2FN)

venta_id	producto_id	nombre_producto	cantidad	precio_unidad	subtotal	nombre_cliente	telefono_cliente
1001	P001	Laptop Dell	2	15000	30000	Juan Pérez	555-0123
1001	P002	Mouse Logitech	3	250	750	Juan Pérez	555-0123
1001	P003	Teclado HP	1	800	800	Juan Pérez	555-0123
1002	P001	Laptop Dell	1	15000	15000	Ana García	555-0456
1002	P004	Monitor Samsung	2	3500	7000	Ana García	555-0456
1003	P002	Mouse Logitech	5	250	1250	Carlos López	555-0789
1003	P003	Teclado HP	2	800	1600	Carlos López	555-0789
1004	P005	Impresora Canon	1	4500	4500	María Torres	555-0321

La 2FN resuelve esto separando cada dato a la tabla donde realmente pertenece:

- nombre_producto y precio_unidad se van a una tabla **PRODUCTOS,** ahí sí dependen completamente de producto_id.
- nombre_cliente y telefono_cliente se van a una tabla **CLIENTES,** ahí dependen de su propio cliente_id.
- En **VENTAS** solo quedan cantidad y subtotal, los únicos datos que sí necesitan el venta_id y el producto_id juntos para tener sentido.

La pregunta clave para detectar violaciones:

¿Puedo saber este dato con solo una parte de mi clave primaria?

Si la respuesta es sí, ese dato está en la tabla equivocada.

¿Qué es la normalización 2fn?

Ejemplo con la Segunda Forma Normal (2FN) y su diagrama entidad relación

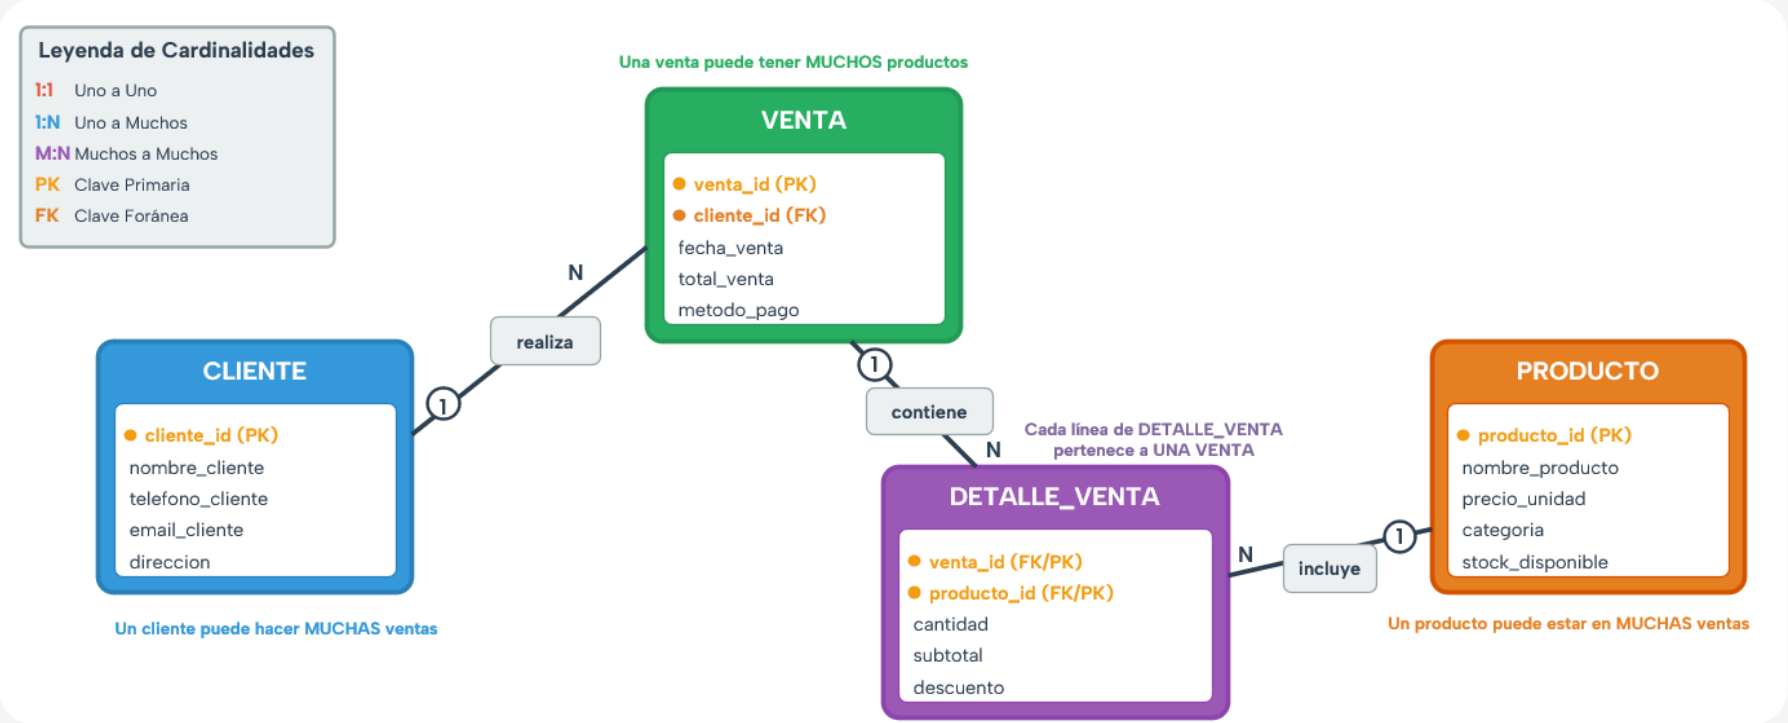

Ejercicio 1: Spotify

Instrucciones

1. Descarga del Drive del curso los archivos:

Ejercicio1_spotify_data_dictionary_Description.csv y Ejercicio1_spotify_history2.csv.

2. Realiza lo siguiente:

2.1 Análisis de los datos

a. Identifica y lista los problemas de normalización encontrados en los archivos originales.
b. Indica qué tablas necesitan separarse y por qué.
c. Especifica qué tablas cumplen con la Primera Forma Normal (1FN) y cuáles con la Segunda Forma Normal (2FN).

2.2 Diagrama Entidad-Relación (ER), toma como base el diagrama adjunto.

a. Diseña el diagrama ER normalizado hasta la 2FN.
b. Usa colores distintos para diferenciar visualmente: entidades, atributos y relaciones.
c. Marca claramente las llaves primarias (PK) y las llaves foráneas (FK).
d. Indica las cardinalidad de cada relación (1:1, 1:N, M:N).
e. Incluye una leyenda que explique los colores y símbolos usados.
f. Incluye la explicación de las cardinalidades.
g. Como título del diagrama incluye tu nombre completo y tu matrícula.
h. Comparte la URL del diagrama en la tarea y la imagen del mismo.

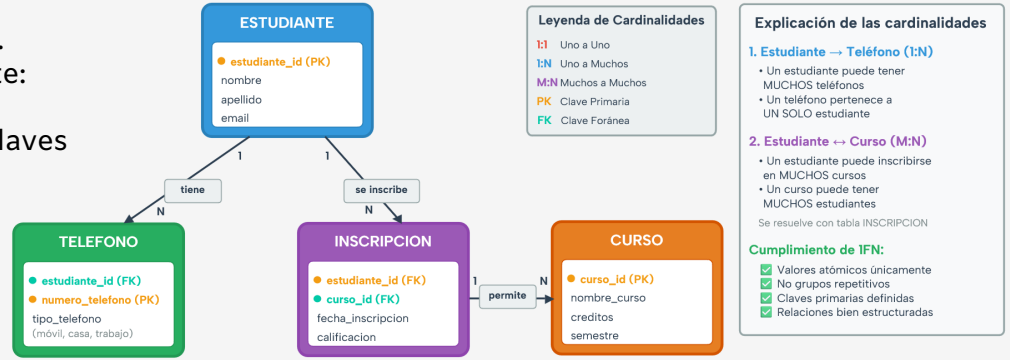

Ejercicio 2: INEGI

Instrucciones

1. Descarga del Drive del curso el archivo: Ejercicio2_inegi.xlsx

2. Realiza lo siguiente:

2.1 Análisis de los datos

a. Identifica y lista los problemas de normalización encontrados en el archivo original.
b. Indica qué columnas representan datos repetidos o dependencias parciales.
c. Especifica qué tablas necesitan separarse para cumplir con la 1FN y la 2FN.

2.2 Diagrama Entidad-Relación (ER)

a. En LucidChart diseña el diagrama ER normalizado hasta la 2FN.
b. Usa dos colores distintos para diferenciar: **entidad catálogo** (tablas de referencia con pocos registros) y **entidad principal** (tabla central con la mayor cantidad de datos).
c. Marca claramente las llaves primarias (PK) y las llaves foráneas (FK) en cada entidad.
d. Nombra las relaciones entre entidades con un verbo que describa la asociación (ejemplo: *tiene, realiza*, *ubicado_en*).
e. Indica la cardinalidad de cada relación (1:N o M:N).
f. Incluye una leyenda que explique los colores, símbolos y la notación de cardinalidad usada.
g. Incluye la explicación de las cardinalidades.
h. Incluye una muestra de 2 o 3 registros de ejemplo dentro de cada entidad para validar que el diseño es correcto.
i. Como título del diagrama incluye tu nombre completo y tu matrícula.
j. Comparte la URL del diagrama en la tarea y la imagen del mismo.

Ejercicio 3: Traders

Instrucciones

Ahora trabajarás con el archivo: Ejercicio3_Traders.xlsx
El documento ya cuenta con la 1FN, hay que ajustar a la 2FN.

Customer_ID	Company	Last Name	First Name	E-mail Address	Job Title	Business Phone	Fax Number	Address	City	State/Province	ZIP/Postal Code	Country/Region
1	Company A	Bedecs	Anna		Owner	(123)555-0100	(123)555-0101	123 1st Street	Seattle	WA	99999	USA
2	Company B	Gratacos Solsona	Antonio		Owner	(123)555-0100	(123)555-0101	123 2nd Street	Boston	MA	99999	USA
3	Company C	Axen	Thomas		Purchasing Representative	(123)555-0100	(123)555-0101	123 3rd Street	Los Angelas	CA	99999	USA
4	Company D	Lee	Christina		Purchasing Manager	(123)555-0100	(123)555-0101	123 4th Street	New York	NY	99999	USA
5	Company E	O'Donnell	Martin		Owner	(123)555-0100	(123)555-0101	123 5th Street	Minneapolis	MN	99999	USA
6	Company F	Pérez-Olaeta	Francisco		Purchasing Manager	(123)555-0100	(123)555-0101	123 6th Street	Milwaukee	WI	99999	USA
7	Company G	Xie	Ming-Yang		Owner	(123)555-0100	(123)555-0101	123 7th Street	Boise	ID	99999	USA
8	Company H	Andersen	Elizabeth		Purchasing Representative	(123)555-0100	(123)555-0101	123 8th Street	Portland	OR	99999	USA
9	Company I	Mortensen	Sven		Purchasing Manager	(123)555-0100	(123)555-0101	123 9th Street	Salt Lake City	UT	99999	USA
10	Company J	Wacker	Roland		Purchasing Manager	(123)555-0100	(123)555-0101	123 10th Street	Chicago	IL	99999	USA
11	Company K	Krschne	Peter		Purchasing Manager	(123)555-0100	(123)555-0101	123 11th Street	Miami	FL	99999	USA
12	Company L	Edwards	John		Purchasing Manager	(123)555-0100	(123)555-0101	123 12th Street	Las Vegas	NV	99999	USA
13	Company M	Ludick	Andre		Purchasing Representative	(123)555-0100	(123)555-0101	456 13th Street	Memphis	TN	99999	USA
14	Company N	Grilo	Carlos		Purchasing Representative	(123)555-0100	(123)555-0101	456 14th Street	Denver	CO	99999	USA
15	Company O	Kupkova	Helena		Purchasing Manager	(123)555-0100	(123)555-0101	456 15th Street	Honolulu	HI	99999	USA
16	Company P	Goldschmidt	Daniel		Purchasing Representative	(123)555-0100	(123)555-0101	456 16th Street	San Francisco	CA	99999	USA
17	Company Q	Bagel	Jean Philippe		Owner	(123)555-0100	(123)555-0101	456 17th Street	Seattle	WA	99999	USA
18	Company R	Autier Miconi	Catherine		Purchasing Representative	(123)555-0100	(123)555-0101	456 18th Street	Boston	MA	99999	USA
19	Company S	Eggerer	Alexander		Accounting Assistant	(123)555-0100	(123)555-0101	789 19th Street	Los Angelas	CA	99999	USA
20	Company T	Li	George		Purchasing Manager	(123)555-0100	(123)555-0101	789 20th Street	New York	NY	99999	USA
21	Company U	Tham	Bernard		Accounting Manager	(123)555-0100	(123)555-0101	789 21th Street	Minneapolis	MN	99999	USA
22	Company V	Ramos	Luciana		Purchasing Assistant	(123)555-0100	(123)555-0101	789 22th Street	Milwaukee	WI	99999	USA
23	Company W	Entin	Michael		Purchasing Manager	(123)555-0100	(123)555-0101	789 23th Street	Portland	OR	99999	USA
24	Company X	Hasselberg	Jonas		Owner	(123)555-0100	(123)555-0101	789 24th Street	Salt Lake City	UT	99999	USA
25	Company Y	Rodman	John		Purchasing Manager	(123)555-0100	(123)555-0101	789 25th Street	Chicago	IL	99999	USA
26	Company Z	Liu	Run		Accounting Assistant	(123)555-0100	(123)555-0101	789 26th Street	Miami	FL	99999	USA
27	Company AA	Toh	Karen		Purchasing Manager	(123)555-0100	(123)555-0101	789 27th Street	Las Vegas	NV	99999	USA
28	Company BB	Raghav	Amritansh		Purchasing Manager	(123)555-0100	(123)555-0101	789 28th Street	Memphis	TN	99999	USA
29	Company CC	Lee	Soo Jung		Purchasing Manager	(123)555-0100	(123)555-0101	789 29th Street	Denver	CO	99999	USA

Customers | Employee_Privileges | Employees | Inventory_Transaction_Types | Inventory_Transactions | Invoices | Order_Details_Status | Order_Details | Orders_Status | Orders_Tax_Status

Ejercicio 3: Traders

El archivo tiene 20 hojas con las siguientes tablas:
1. Customers, 2. Employee_Privileges, 3. Employees, 4. Inventory_Transaction_Types, 5. Inventory_Transactions, 6. Invoices, 7. Order_Details_Status, 8. Order_Details, 9. Orders_Status, 10. Orders_Tax_Status, 11. Orders, 12. Privileges, 13. Products, 14. Purchase_Order_Details, 15. Purchase_Order_Status, 16. Purchase_Orders, 17. Sales_Reports, 18. Shippers, 19. Strings, 20. Suppliers

Realiza el diagrama ER:

a. En LucidChart diseña el diagrama ER normalizado hasta la 2FN.
b. Usa dos colores distintos para diferenciar: **entidad catálogo** (tablas de referencia con pocos registros) y **entidad principal** (tabla central con la mayor cantidad de datos).
c. Marca claramente las llaves primarias (PK) y las llaves foráneas (FK) en cada entidad.
d. Nombra las relaciones entre entidades con un verbo que describa la asociación (ejemplo: *tiene, vender, realiza*, *ubicado_en*).
e. Indica la cardinalidad de cada relación (1:N o M:N).
f. Incluye la explicación de las cardinalidades.
g. Incluye una leyenda que explique los colores, símbolos y la notación de cardinalidad usada.
h. Incluye una muestra de 2 o 3 registros de ejemplo dentro de cada entidad para validar que el diseño es correcto.
i. Como título del diagrama incluye tu nombre completo y tu matrícula.
j. Comparte la URL del diagrama en la tarea y la imagen del mismo.